Sprawozdanie z projektu: Cechy sygnału audio w dziedzinie czasu

Wiktor Murawski

1 kwietnia 2026

1 Wstęp i opis aplikacji

Celem projektu było stworzenie aplikacji okienkowej umożliwiającej wczytanie pliku dźwiękowego w formacie `.wav`, wizualizację przebiegu czasowego oraz obliczenie i prezentację wybranych parametrów sygnału (m.in. głośności, energii krótkoczasowej, współczynnika przejść przez zero oraz wskaźnika ciszy).

Aplikacja została zrealizowana w języku `C#` (`.NET 10`) z wykorzystaniem frameworku `Windows Forms`. Do wizualizacji sygnałów wykorzystano bibliotekę `ScottPlot 5`, a do wczytywania plików audio - bibliotekę `NAudio`.

Główne cechy aplikacji:

- Wczytywanie plików `.wav` (mono lub stereo o dowolnej częstotliwości próbkowania)
- Wyświetlanie przebiegu fali z synchronizacją osi czasu między wykresami
- Obliczanie i wizualizacja parametrów w dziedzinie czasu na poziomie ramki
- Obliczanie parametrów w dziedzinie czasu na poziomie całego wczytanego klipu
- Możliwość zmiany parametrów używanych do obliczania niektórych cech
- Automatyczne oznaczanie fragmentów ciszy
- Możliwość zmiany rozmiaru ramki
- Eksport wyników do pliku CSV

Intefejs użytkownika

Interfejs aplikacji (przedstawiony na Rysunku 1):

- Pozwala użytkownikowi wczytać plik `.wav` (`Plik > Wczytaj plik audio`)
- Pozwala użytkownikowi wyeksportować parametry do pliku `.csv` (`Plik > Export > ...`)
- Wyświetla wykres oryginalnego sygnału oraz wykresy parametrów wyznaczonych na poziomie ramek z lewej strony okna

- Umożliwia ustawienie rozmiaru ramki oraz parametrów używanych w obliczeniach z prawej strony okna
- Prezentuje wyznaczone parametry na poziomie klipu w prawym dolnym rogu okna

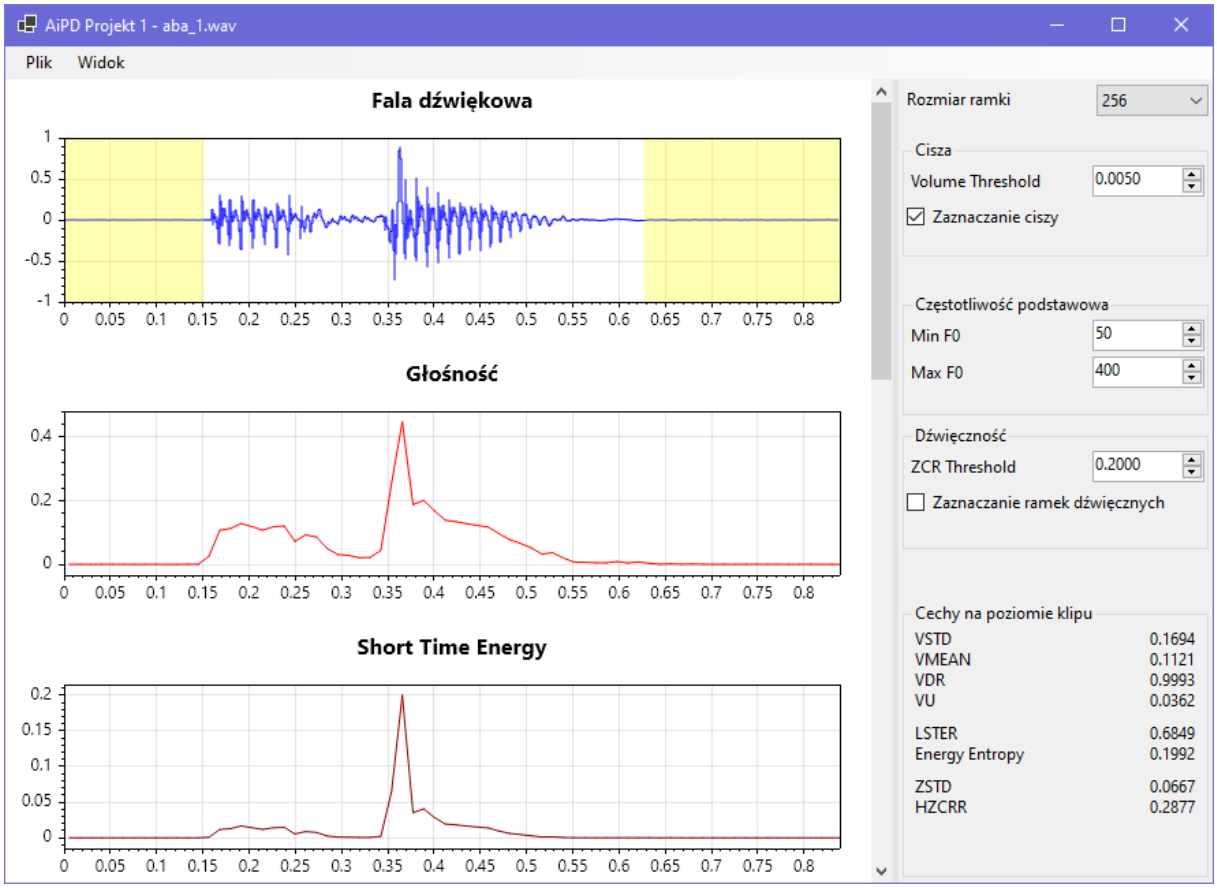

Rysunek 1: Przykładowy wygląd interfejsu aplikacji po wczytaniu krótkiego sygnału mowy (słowo "aba")

2 Opis zastosowanych metod

Wczytywanie sygnału

Plik audio jest wczytywany za pomocą `AudioFileReader` z biblioteki `NAudio`. W przypadku pliku mono próbki wczytywane są od razu, w przypadku pliku stereo jest on konwertowany do sygnału mono poprzez wzięcie średniej z obu kanałów. Dla większej liczby kanałów wyświetlany jest błąd o nieobsługiwanej liczbie kanałów.

Podział sygnału na ramki

Po wczytaniu sygnał jest dzielony na ramki o długości ustalonej przez użytkownika (do wyboru ramki długości 128, 256, 512 lub 1024 próbek). W przypadku gdy ilość wczytanych próbek nie jest podzielna przez rozmiar ramki, ostatnia ramka dopełniana jest zerami.

2.1 Cechy sygnału audio w dziedzinie czasu na poziomie ramki

2.1.1 Głośność (Volume)

Głośność obliczana jest w każdej ramce według wzoru:

$$p\left(n\right) = \sqrt{\frac{1}{N}\sum_{i=0}^{N-1} s_n^2(i)}$$

gdzie N oznacza długość ramki w próbkach, $s_n(i)$ oznacza amplitudę i-tej próbki w n-tej ramce.

2.1.2 Energia krótkoczasowa (Short-Time Energy)

Energia obliczana jest w oknach ramek według wzoru:

$$STE(m) = \frac{1}{N}\sum_{i=0}^{N-1} s_n^2(i)$$

gdzie N oznacza długość ramki w próbkach, $s_n(i)$ oznacza amplitudę i-tej próbki w n-tej ramce.

Innymi słowy jest to głośność podniesiona do kwadratu.

2.1.3 Współczynnik przejść przez zero (Zero Crossing Rate)

Liczba przejść amplitudy przez zero w ramce sygnału wyznaczana według wzoru:

$$ZCR(n) = \frac{1}{2N}\sum_{i=1}^{N-1} |\mathrm{sign}(s_n(i)) - \mathrm{sign}(s_n(i-1))|$$

gdzie N oznacza długość ramki w próbkach, $s_n(i)$ oznacza amplitudę i-tej próbki w n-tej ramce.

2.1.4 Ciche ramki (Silent Ratio)

Ramka jest klasyfikowana jako cisza jeśli spełniony jest warunek:

$$p(n) \leq p_{threshold}$$

gdzie $p(n)$ to głośność wyznaczona dla ramki n, a $p_{threshold}$ to próg głośności ustawiany przez użytkownika (domyślnie próg ma wartość 0,005). Innymi słowy ramka jest cicha gdy energia w niej jest bardzo niska.

2.1.5 Ramki dźwięczne

Ramka jest klasyfikowana jako dźwięczna jeśli spełnione są warunki:

$$p(n) > p_{threshold}$$

$$ZCR(n) \leq ZCR_{threshold}$$

gdzie $p(n)$ to głośność wyznaczona dla ramki n, $ZCR(n)$ to współczynnik przejść przez zero w ramce n, $p_{threshold}$ to próg głośności (ten sam, który wykorzystywany jest przy klasyfikacji ciszy), a $ZCR_{threshold}$ to próg ZCR; oba progi ustawiane mogą być przez użytkownika (domyślnie progi mają wartości kolejno 0,005 i 0,08).

2.1.6 Fundamentalna częstotliwość - Autokorelacja

Metoda polega na wyszukiwaniu maksimum funkcji autokorelacji danej wzorem:

$$R_n(l) = \sum_{i=0}^{N-l-1} s_n(i)s_n(i+l)$$

gdzie N oznacza długość ramki w próbkach, $s_n(i)$ oznacza amplitudę i-tej próbki w n-tej ramce.

Wyszukiwanie odbywa się w ograniczonym zakresie parametru l (ustalonym przez użytkownika poprzez ustawienie minimalnej i maksymalnej częstotliwości).

2.1.7 Fundamentalna częstotliwość - AMDF (Average Magnitude Difference Function)

Metoda polega na minimalizacji funkcji różnicy amplitud danej wzorem:

$$A_n(l) = \sum_{i=0}^{N-l-1} |s_n(i+l) - s_n(i)|$$

gdzie N oznacza długość ramki w próbkach, $s_n(i)$ oznacza amplitudę i-tej próbki w n-tej ramce.

Wyszukiwanie odbywa się w ograniczonym zakresie parametru l (ustalonym przez użytkownika poprzez ustawienie minimalnej i maksymalnej częstotliwości).

2.2 Cechy sygnału audio w dziedzinie czasu na poziomie klipu

2.2.1 VSTD - Odchylenie standardowe głośności normalizowane przez maksymalną głośność

VSTD jest miarą statystyczną głośności obliczonej dla ramek w klipie. Odchylenie standardowe jest normalizowane przez maksymalną wartość głośności w całym klipie:

$$VSTD = \frac{\sigma(v)}{\max(v)}$$

gdzie $\sigma(v)$ to odchylenie standardowe głośności, a $\max(v)$ to maksymalna głośność w klipie.

2.2.2 VMEAN - Średnia głośności normalizowana przez maksymalną głośność

VMEAN jest miarą statystyczną głośności obliczonej dla ramek w klipie. Odchylenie standardowe jest normalizowane przez maksymalną wartość głośności w całym klipie:

$$VSTD = \frac{\mu(v)}{\max(v)}$$

gdzie $\mu(v)$ to średnia głośność, a $\max(v)$ to maksymalna głośność w klipie.

2.2.3 VDR - Rozpiętość tonalna głośności

VDR (Volume Dynamic Range) liczony jest następująco:

$$VDR = \frac{\max(v) - \min(v)}{\max(v)}$$

gdzie $\max(v)$ to maksymalna głośność w klipie, a $\min(v)$ to minimalna głośność w klipie.

2.2.4 LSTER - Niski współczynnik energii krótkoterminowej

Wartość LSTER (Low Short Time Energy Ratio) wyznaczana jest według wzoru:

$$LSTER = \frac{1}{2N} \sum_{n=0}^{N-1} \left[sign\left(0.5 \cdot avSTE - STE(n)\right) + 1 \right]$$

gdzie N jest całkowitą liczbą ramek, $STE(n)$ jest to STE w n-tej ramce, i $avSTE$ jest średnią wartością STE w klipie.

2.2.5 VU - Falistość głośności

Wartość VU (Volume Undulation) jest wyznaczana poprzez obliczenie średniej bezwzględnej różnicy między sąsiednimi pikami i dolinami konturu głośności:

$$VU = \frac{1}{M-1} \sum_{i=1}^{M-1} |E_i - E_{i+1}|$$

gdzie M to liczba ekstremów, a E_i to kolejne ekstrema lokalne.

2.2.6 Entropia energii (Energy Entropy)

Wartość entropii energii wyznaczana jest na podstawie wzoru:

$$I = -\frac{1}{J} \sum_{i=1}^{J} \sigma_i^2 \log_2 \sigma_i^2$$

gdzie J jest całkowitą liczbą segmentów w klipie podzielonym na segmenty o długości K (w aplikacji przyjęto $K = 16$), a σ_i^2 jest energią i-tego segmentu znormalizowaną przez całkowitą energię ramki, w której jest segment.

2.2.7 ZSTD - Odchylenie standardowe ZCR

ZSTD jest miarą statystyczną ZCR obliczoną dla ramek w klipie:

$$ZSTD = \sigma(ZCR)$$

2.2.8 HZCRR - Wysoki współczynnik przejść przez zero

HZCRR (High Zero Crossing Rate Ratio) obliczany jest ze wzoru:

$$HZCRR = \frac{1}{2N} \sum_{n=0}^{N-1} \left[sign(ZCR(n) - 1.5 \cdot avZCR) + 1 \right]$$

gdzie N jest liczbą ramek, $ZCR(n)$ jest wartością ZCR w n-tej ramce, a $avZCR$ jest średnią wartością ZCR w klipie.

3 Wyniki

3.1 Wykrywanie ciszy

Aplikacja wykrywa ciszę w ramce biorąc pod uwagę głośność ramki. Dla cichej ramki głośność jest bardzo niska.

Na Rysunku 2 przedstawiono przebieg fali dźwiękowej dla słowa *chrząszcz* wraz z zaznaczoną na żółto ciszą. Na Rysunku 3 przedstawiono przebieg głośności wyznaczonej dla kolejnych ramek w tym sygnale, natomiast na Rysunku 4 przedstawiono przebieg ZCR. Można zauważyć, że na podstawie ZCR zakwalifikować ramkę jako ciszę lub nie - mowa zawiera wartości ZCR zarówno wyższe jak i niższe od ciszy. Głośność natomiast pozwala w miarę trafnie zakwalifikować ramki jako ciszę.

Rysunek 2: Przebieg fali dźwiękowej dla słowa *chrząszcz* (długość ramki = 256)

Rysunek 3: Przebieg głośności dla słowa *chrząszcz* (długość ramki = 256)

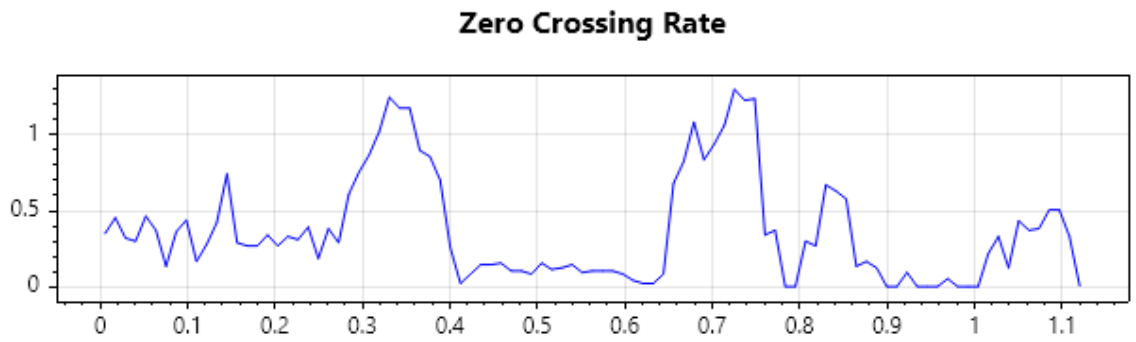

Rysunek 4: Przebieg ZCR dla słowa *chrząszcz* (długość ramki = 256)

3.2 Określenie fragmentów dźwięcznych / bezdźwięcznych

Aplikacja wykrywa fragmenty (ramki) dźwięczne porównując głośność i ZCR ramki z ustalonymi progami.

Na Rysunku 5 przedstawiono wykres sygnału audio dla słowa *dziewięć*, wraz z zaznaczoną ciszą (na żółto) oraz z zaznaczonymi fragmentami dźwięcznymi (na zielono). Można zauważyć, że fragmenty dźwięczne charakteryzuje zauważalnie niższy ZCR niż w przypadku mowy bezdźwięcznej, która bardziej przypomina głośny szum.

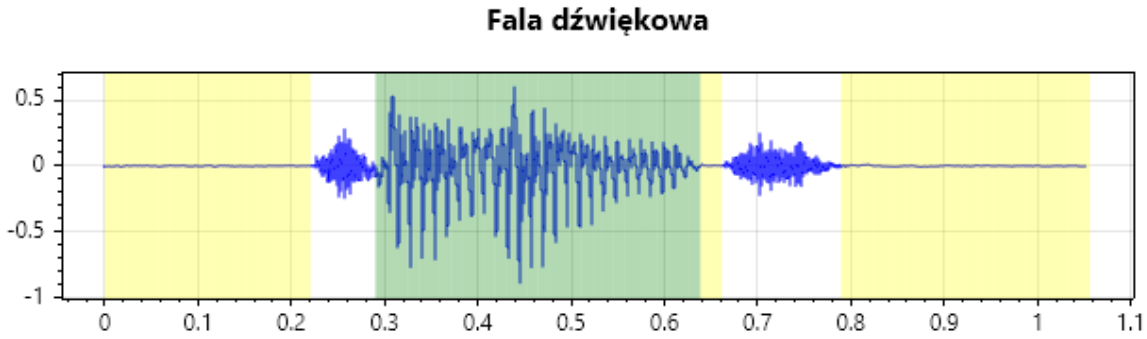

Rysunek 5: Przebieg fali dźwiękowej dla słowa *dziewięć* (długość ramki = 256)

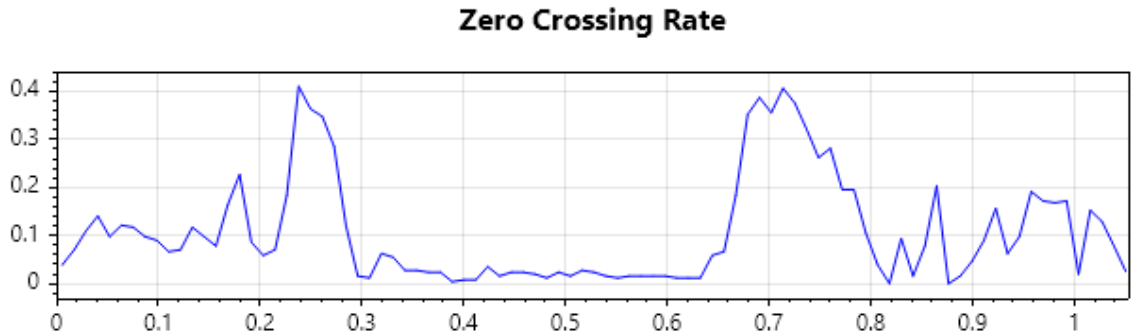

Rysunek 6: Przebieg ZCR dla słowa *dziewięć* (długość ramki = 256)

3.3 Porównanie fragmentów muzyka / mowa

Muzykę od mowy można odróżnić na przykład poprzez:

- **Zmienność energii w czasie (energy contour)** - Mowa ma bardzo nieregularną, „szarpaną” energię (duże różnice między sylabami i pauzami). Muzyka jest zwykle bardziej równomierna lub ma powtarzalny rytm.
- **Współczynnik przejść przez zero (ZCR)** - Mowa ma wyższą średnią i większą wariancję ZCR (dużo bezdźwięcznych spółgłosek). Muzyka (zwłaszcza harmoniczna) ma często niższy i bardziej stabilny ZCR.

4 Wnioski

Realizacja projektu pozwoliła na praktyczne zrozumienie klasycznych metod analizy sygnału audio w dziedzinie czasu oraz ich ograniczeń w warunkach rzeczywistych.

Aplikacja dobrze radzi sobie z przetwarzaniem krótkich sygnałów dźwiękowych, jednak przy nagraniach dłuższych, i o wyższej częstotliwości próbkowania, pojawiają się problemy wydajnościowe, a pliki o zbyt dużej ilości próbek nie są obsługiwane przez aplikację w ogóle, ze względu na przechowywanie wczytanych próbek w pamięci. Obsługę dłuższych plików można by zaimplementować na przykład poprzez wczytywanie próbek (i ich przetwarzanie) partiami.

Wykrywanie ciszy oraz klasyfikacja fragmentów dźwięcznych wymaga indywidualnego dostosowania progów dla wczytanego pliku, co potwierdza niską uniwersalność sztywnych wartości progowych.

Klasyczne metody wyznaczania częstotliwości tonu podstawowego (autokorelacja i AMDF) są proste w implementacji, jednak obarczone istotnymi ograniczeniami - szczególnie przy sygnałach zaszumionych lub niestabilnych - oraz wymagają dostosowania przedziału szukanej częstotliwości. Żadna z nich nie daje w pełni satysfakcjonujących wyników, wyniki są ciężkie do interpretacji.